

LAPORAN ANALISIS & MODELING DEEP LEARNING DATASET AMES HOUSING



Disusun Oleh:

Gibran Rais Hilmy Iskandar

A11.2023.15270

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS DIAN NUSWANTORO

2025

1. Tujuan Utama Analisis

Tujuan utama analisis ini adalah **membangun model Deep Learning untuk memprediksi harga rumah (SalePrice)** menggunakan dataset Ames Housing. Tujuan ini dipilih karena:

- Dataset kaya fitur (82 variabel) sehingga cocok untuk model Deep Learning.
- Prediksi harga rumah merupakan kasus bisnis umum (real estate valuation).
- Model dapat digunakan oleh pemangku kepentingan seperti developer properti, bank, atau agen real estate untuk meningkatkan akurasi estimasi harga.

Model akan menggunakan pendekatan **Supervised Deep Learning – Regresi**.

2. Deskripsi Dataset

Dataset **AmesHousing.csv** berisi **~80+ fitur** mencakup karakteristik rumah seperti:

- Luas tanah (Lot Area), kondisi rumah
- Luas bangunan (Gr Liv Area)
- Tahun dibangun (Year Built)
- Jumlah kamar
- Tipe garasi, kualitas material
- Lokasi (zoning, neighborhood)

Target variabel:

SalePrice → harga jual rumah.

Dataset ini ideal karena:

- Data cukup bersih
- Variabel numerik & kategorikal kaya
- Cocok untuk eksperimen model berbasis neural network

3. EDA & Prapemrosesan Data

3.1. Exploratory Data Analysis

Dari analisis awal:

- Distribusi SalePrice *right-skewed* (banyak rumah harga menengah, sedikit rumah mahal)
- Terdapat korelasi tinggi antara SalePrice dan:

- OverallQual
- GrLivArea
- TotalBsmtSF
- GarageCars

3.2. Data Cleaning

Tindakan yang dilakukan:

- Mengisi missing value numerik dengan median.
- Mengisi kategori yang hilang dengan nilai “None”.
- Menghapus kolom dengan missing value ekstrem ($\geq 30\%$).
- Encoding kategori menggunakan **One-Hot Encoding**.
- Normalisasi fitur numerik menggunakan **StandardScaler**.

4. Variasi Model Deep Learning

Tiga arsitektur diuji:

◆ Model 1 – Simple Neural Network (Baseline)

- 2 hidden layers (64, 32 neurons)
- ReLU activation
- Optimizer: Adam
- Epoch: 50

◆ Model 2 – Deep Neural Network (Improved)

- 5 hidden layers
 - (128, 64, 64, 32, 16)
- Batch Normalization
- Dropout 0.3
- Optimizer: AdamW
- Epoch: 100

◆ **Model 3 – Wide & Deep Network**

- 2 komponen: wide features + deep features
- Kombinasi interaksi non-linear + linear
- Cocok untuk tabular data dengan banyak kategori
- Epoch: 120

5. Rekomendasi Model Terbaik

Model terbaik adalah:

Model 2 – Deep Neural Network (Improved)

Karena:

- RMSE paling rendah
- Overfitting terkecil berkat Dropout + BatchNorm
- Stabil pada data validasi
- Performa lebih baik menangkap non-linearitas harga rumah

6. Temuan & Insight Utama

- **Fitur paling berpengaruh terhadap harga rumah:**
 - OverallQual
 - GrLivArea
 - GarageCars
 - TotalBsmtSF
- **Rumah yang dibangun setelah tahun 2000 rata-rata memiliki harga lebih tinggi.**
- **Luas bangunan (livable area)** adalah variabel paling konsisten memengaruhi harga.
- Model deep learning mampu menangkap pola kompleks antar fitur yang tidak tampak jelas pada regresi linear.

7. Keterbatasan & Langkah Selanjutnya

Keterbatasan

- Dataset memiliki jumlah fitur sangat besar → memerlukan feature selection lanjut.

- Beberapa kategori sparse masih sulit dipelajari model.
- Model belum diuji pada data real-world di luar dataset Ames.

Langkah selanjutnya

1. Menambah dataset real estate eksternal.
2. Hyperparameter tuning (Bayesian Optimization).
3. Mencoba model lebih canggih seperti:
 - TabTransformer
 - Neural Oblivious Decision Ensembles (NODE)
4. Menggunakan SHAP untuk interpretabilitas model.

LAMPIRAN