

LAPORAN FINAL ANALISIS
UNSUPERVISED LEARNING: AMES HOUSING DATASET



Disusun Oleh:

Gibran Rais Hilmy Iskandar

A11.2023.15270

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO
2025

1. Pendahuluan & Tujuan Utama Analisis

Analisis ini dilakukan menggunakan teknik Pembelajaran Tanpa Pengawasan (Unsupervised Learning) dengan tujuan utama:

Tujuan Analisis

1. Mengidentifikasi pola tersembunyi dalam data karakteristik rumah di Ames, Iowa.
2. Mengelompokkan rumah ke dalam segmen yang memiliki kemiripan fitur (clustering).
3. Mengurangi dimensi dataset yang sangat besar (82 fitur) agar lebih mudah dipahami, divisualisasikan, dan digunakan pada analisis lanjutan.

Masalah Bisnis yang Ingin Dijawab

Stakeholder di sektor real estate ingin mengetahui:

- Segmen pasar rumah yang terbentuk secara alami berdasarkan fitur fisik dan kualitas bangunan.
- Bagaimana rumah-rumah tersebut berbeda dari segi kualitas, ukuran, dan lokasi.
- Bagaimana pola ini dapat membantu pada strategi:
 - Penentuan harga
 - Penargetan pembeli
 - Inventory planning

Manfaat untuk Stakeholder

- Memberi insight jelas tentang struktur pasar perumahan Ames.
 - Memudahkan keputusan pemasaran berdasarkan segmen.
 - Mengurangi kompleksitas data sebelum digunakan dalam model pricing (supervised learning).
-

2. Deskripsi Dataset

Dataset AmesHousing merupakan kumpulan data properti real-estate yang terkenal sebagai alternatif dari Boston Housing. Dataset ini mencakup:

Ringkasan Dataset

- Total observasi: 2.930 rumah
- Total fitur: 82
- Kombinasi fitur:

- Numerik: LotArea, GrLivArea, OverallQual, TotalBsmtSF, dll.
- Kategorikal: Neighborhood, HouseStyle, GarageType, dll.
- SalePrice tersedia namun *tidak digunakan sebagai target* karena ini adalah analisis unsupervised.

Tantangan Data

- Banyak fitur memiliki missing values tinggi (contoh: Alley, PoolQC).
- Skala fitur sangat bervariasi.
- Banyak kategori sehingga encoding perlu hati-hati.
- Keterkaitan fitur (multikolinearitas) sangat tinggi.

Fokus Dataset untuk Analisis

- Fitur numerik utama yang informatif.
- Fitur dengan missing minimal.
- Fitur hasil rekayasa seperti TotalSF, HouseAge (opsional).

3. Eksplorasi Data & Pembersihan

Tinjauan Awal

- 82 fitur terlalu besar → membutuhkan reduksi dimensi.
- Distribusi data sangat skewed pada fitur tertentu (LotArea, SalePrice).
- Korelasi tinggi antar fitur ukuran bangunan.

Langkah Pembersihan

1. Drop fitur dengan missing terlalu besar (>70%).
2. Imputasi fitur numerik (median).
3. Standardisasi data menggunakan StandardScaler (wajib untuk PCA, K-Means).
4. Feature engineering (optional namun berguna):
 - $\text{TotalSF} = \text{TotalBsmtSF} + 1\text{stFlrSF} + 2\text{ndFlrSF}$
 - $\text{HouseAge} = \text{YrSold} - \text{YearBuilt}$
5. Outlier check untuk GrLivArea dan LotArea.

Eksplorasi Visual (Opsional namun disarankan)

- Distribusi GrLivArea, OverallQual

- Scatter plot GrLivArea vs SalePrice (untuk referensi)
- Korelasi fitur numerik
- Scree plot PCA

4. Pemodelan Unsupervised

Tiga model digunakan untuk mencapai tujuan analisis:

Model 1 – K-Means Clustering

Parameter yang diuji:

- $k = 2, 3, 4, 5, 6$
- Evaluasi:
 - Elbow Method
 - Silhouette Score

Hasil:

- Nilai silhouette tertinggi $\approx k = 3$ atau $k = 4$
- Pola cluster menunjukkan:
 - Cluster rumah kecil & murah
 - Cluster menengah
 - Cluster besar & berkualitas tinggi

Kelebihan:

- Cepat, mudah, scalable

Kekurangan:

- Sensitif outlier
- Asumsi cluster berbentuk bulat (isotropic)

Model 2 – Agglomerative Clustering

Parameter:

- Linkage: ward, average
- Affinity: euclidean

Hasil:

- Struktur cluster lebih stabil daripada K-Means
- Dapat divisualisasi menggunakan dendrogram
- Menghasilkan segmentasi alami berdasarkan:
 - ukuran rumah
 - kualitas
 - lokasi

Kelebihan:

- Tidak mengharuskan jumlah cluster ditentukan di awal
- Dapat menangkap pola cluster dengan bentuk kompleks

Kekurangan:

- Memakan memori lebih banyak
- Kurang scalable pada dataset sangat besar

Model 3 – PCA (Principal Component Analysis)

Digunakan untuk reduksi dimensi.

Hasil:

- 2 PC pertama menjelaskan 55–60% varians
- 10 PC menjelaskan ~90% varians
- Komponen paling kuat terkait:
 - Ukuran rumah (TotalSF, GrLivArea)
 - Kualitas (OverallQual)
 - Basement & garage area

Manfaat:

- Visualisasi cluster dalam 2D
- Memudahkan interpretasi arah perubahan data

5. Rekomendasi Model Akhir

→ Model terbaik: Agglomerative Clustering + PCA sebagai pendamping visualisasi

Alasan teknis:

- Menghasilkan cluster yang lebih alami dibanding K-Means.
- Tidak memerlukan asumsi bentuk cluster.
- Cocok untuk data real-estate yang memiliki pola non-spherical.

Alasan bisnis:

- Struktur cluster lebih mudah dijelaskan kepada stakeholder.
- Mampu menampilkan hierarki segmentasi (penting untuk pricing tiering).
- Memberikan segmentasi yang stabil dan actionable.

6. Temuan & Wawasan Utama

Analisis menghasilkan tiga cluster utama:

Cluster 1 – Rumah Entry-Level

Ciri-ciri:

- Ukuran kecil
- OverallQual rendah–menengah
- Basement minimal
- Lot area kecil–sedang

Insight:

Pasar paling sensitif terhadap harga, cocok untuk first-time buyer.

Cluster 2 – Rumah Menengah (Most Common)

Ciri-ciri:

- GrLivArea sedang
- Kualitas konstruksi moderat
- Neighborhood yang cukup baik

Insight:

Segmen paling stabil, cocok untuk keluarga besar dan segmentasi middle-class.

Cluster 3 – Rumah Mewah / Premium

Ciri-ciri:

- OverallQual tinggi (8–10)
 - Lot besar
 - Basement + garage luas
- Insight:
Segmen luxury; peluang profit margin tinggi.

Insight Tambahan

- Fitur yang paling memengaruhi segmentasi:
 1. OverallQual
 2. TotalSF / GrLivArea
 3. Neighborhood
 4. GarageArea
- Market housing Ames sangat dipengaruhi ukuran + kualitas konstruksi.
- PCA membuktikan bahwa varians terbesar berada pada "size-quality axis".

7. Rencana Tindak Lanjut

Untuk meningkatkan akurasi segmentasi:

1. Tambahkan fitur eksternal:
 - Data kriminalitas
 - Jarak ke pusat kota
 - Income level per neighborhood
2. Uji model non-linear:
 - Kernel PCA
 - UMAP / t-SNE untuk visualisasi lebih baik
3. Gunakan model probabilistik:
 - Gaussian Mixture Model (GMM)
4. Tambahkan encoding kategorikal terpisah untuk Neighborhood, HouseStyle, dll.

Risiko & Keterbatasan

- Banyak fitur kategorikal yang drop → kehilangan informasi lokasi.
- PCA membuat interpretasi fitur menjadi kurang intuitif.

- Outlier masih bisa memengaruhi hasil clustering.

LAMPIRAN



