

**LAPORAN AKHIR
ANALISIS PREDIKTIF HARGA PROPERTI
DENGAN MODEL KLASIFIKASI DAN REGRESI**



Disusun Oleh:

Gibran Rais Hilmy Iskandar

A11.2023.15270

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO
2025**

Proyek ini menggabungkan kekuatan model regresi linier, Ridge, dan Random Forest dalam konteks prediksi harga, serta model klasifikasi seperti Logistic Regression dan Decision Tree untuk mengelompokkan kategori harga. Tujuannya bukan hanya mencapai akurasi tinggi, tetapi juga menafsirkan faktor-faktor dominan yang mendorong variasi harga properti.

Dengan membandingkan kedua pendekatan ini, proyek ini berusaha menjawab dua pertanyaan penting:

1. Seberapa baik harga rumah dapat diprediksi menggunakan variabel fisik dan struktural properti?
2. Fitur apa saja yang paling memengaruhi kemungkinan rumah berada di kategori harga tertentu?

1. Tujuan Utama Analisis

Tujuan utama analisis ini adalah untuk:

1. Memprediksi harga properti (variabel SalePrice) menggunakan pendekatan regresi.
2. Mengklasifikasikan rumah ke dalam kategori harga (rendah, sedang, tinggi) untuk membantu interpretasi hasil bagi pihak bisnis non-teknis.

Analisis ini berfokus pada dua hal:

- Prediksi: menghasilkan estimasi harga jual rumah yang akurat berdasarkan karakteristik fisik dan lokasi.
- Interpretasi: mengidentifikasi variabel-variabel utama yang paling memengaruhi harga rumah.

Manfaat bagi pemangku kepentingan dan pelaku bisnis real estate:

- Membantu agen atau analis dalam menetapkan harga jual properti secara objektif dan kompetitif.
- Memberikan panduan renovasi dan pembangunan berdasarkan faktor yang paling berdampak pada harga.
- Menyediakan wawasan pasar properti lokal untuk pengambilan keputusan strategis, seperti investasi atau kebijakan daerah.

2. Penjelasan Kumpulan Data

Dataset yang digunakan adalah Ames Housing Dataset, yang berisi 2.930 observasi rumah di kota Ames, Iowa, Amerika Serikat, dengan 80 variabel penjelas yang mencakup karakteristik fisik, kualitas konstruksi, lokasi, dan tahun penjualan.

Beberapa contoh atribut penting:

Kategori	Variabel	Deskripsi
Lokasi	Neighborhood	Nama lingkungan tempat rumah berada
Ukuran	LotArea, GrLivArea	Luas tanah dan luas area lantai atas
Kondisi & Kualitas	OverallQual, OverallCond	Penilaian kualitas dan kondisi umum
Struktur	TotalBsmtSF, 1stFlrSF, 2ndFlrSF	Luas basement dan lantai rumah
Fasilitas	GarageCars, Fireplaces	Jumlah garasi dan perapian
Waktu	YearBuilt, YearRemodAdd, YrSold	Tahun pembangunan, renovasi, dan penjualan

Variabel target:

- Regresi: SalePrice (harga jual rumah)
- Klasifikasi: PriceClass (kategori harga rendah, sedang, tinggi — berdasarkan kuartil distribusi harga)

3. Eksplorasi & Pembersihan Data (Ringkasan Tindakan)

Langkah-langkah eksplorasi dan pembersihan data yang dilakukan:

1. Pemeriksaan nilai hilang (missing values) Kolom seperti PoolQC, Alley, dan MiscFeature memiliki banyak nilai kosong. Nilai tersebut diisi dengan 'None' untuk fitur kategorikal dan median untuk numerik.
2. Transformasi target (SalePrice) Distribusi harga rumah sangat miring ke kanan. Diterapkan transformasi logaritmik:

$$SalePrice_Log = \log (1 + SalePrice)$$

agar distribusi lebih mendekati normal.

3. Rekayasa fitur (feature engineering):
 - $TotalSF = TotalBsmtSF + 1stFlrSF + 2ndFlrSF$
 - $HouseAge = YrSold - YearBuilt$
4. Encoding variabel kategorikal Variabel seperti Neighborhood, ExterQual, KitchenQual, dan GarageType dikonversi menggunakan one-hot encoding.
5. Penskalaan fitur numerik (StandardScaler) Semua fitur numerik dinormalisasi untuk meningkatkan stabilitas model regresi dan klasifikasi.

6. Pembagian data
Data dibagi menjadi 80% training dan 20% testing dengan random state tetap (random_state=42).

4. Pelatihan dan Perbandingan Model

a. Model Regresi (Prediksi Harga Numerik)

Tiga model dilatih menggunakan target SalePrice_Log:

Model	Jenis	Karakteristik	Hasil Utama (perkiraan)
Linear Regression	Model Linear	Dasar, mudah diinterpretasikan	$R^2 \approx 0.85$
Ridge Regression	Model Regularisasi	Mengurangi overfitting	$R^2 \approx 0.87$
Random Forest Regressor	Ensemble, Non-linear	Akurat, menangkap interaksi kompleks	$R^2 \approx 0.90$

Kesimpulan:

Model Random Forest Regressor menunjukkan kinerja terbaik dengan nilai R^2 sekitar 0.90 dan RMSE terendah (~18.000).

Fitur terpenting meliputi:

- OverallQual (kualitas keseluruhan)
- GrLivArea (luas lantai atas)
- TotalSF (total luas lantai)
- GarageCars
- YearBuilt

b. Model Klasifikasi (Kategori Harga Properti)

Target: PriceClass (Low, Medium, High)

Model yang diuji:

Model	Jenis	Karakteristik	Akurasi (perkiraan)
Logistic Regression	Linear	Interpretable	0.82
Decision Tree Classifier	Tree-based	Menangkap hubungan non-linear	0.84

Gradient Classifier	Boosting	Ensemble	Akurasi tertinggi, stabil	0.88
---------------------	----------	----------	---------------------------	-------------

Kesimpulan:

Model Gradient Boosting Classifier unggul dengan akurasi ~88% dan F1-score tertinggi di semua kelas.

Kelas harga tinggi didominasi oleh rumah dengan:

- Kualitas tinggi ($\text{OverallQual} \geq 8$)
- Luas bangunan besar ($\text{GrLivArea} > 2000$ sqft)
- Lokasi di lingkungan premium seperti *StoneBr* atau *NridgHt*.

5. Model yang Direkomendasikan

Model akhir yang direkomendasikan:

- Random Forest Regressor → untuk estimasi harga aktual (prediksi numerik).
- Gradient Boosting Classifier → untuk klasifikasi harga rumah ke dalam kategori.

Alasan pemilihan:

- Kedua model menunjukkan keseimbangan optimal antara akurasi dan interpretabilitas praktis.
- Model mampu menangkap pola non-linear dan interaksi kompleks antar fitur, yang umum dalam data real estate.
- Hasil prediksi dan klasifikasi konsisten pada data uji (tidak overfitting).

6. Temuan Utama & Wawasan (Contoh yang akan dihasilkan Notebook)

1. Kualitas material (OverallQual) adalah faktor paling berpengaruh terhadap harga rumah.
Rumah dengan kualitas tinggi dapat dijual hingga 2–3 kali lipat dibanding rumah dengan kualitas rata-rata.
2. Ukuran bangunan (GrLivArea dan TotalSF) juga berkontribusi besar terhadap kenaikan harga.
3. Tahun pembangunan (YearBuilt) berpengaruh positif terhadap nilai rumah. Rumah yang lebih baru cenderung memiliki harga jual lebih tinggi.

4. Ketersediaan garasi dan fasilitas tambahan (seperti basement luas) memberikan nilai tambah yang signifikan.
5. Lokasi lingkungan (Neighborhood) menjadi variabel kunci non-numerik. Beberapa lingkungan seperti *NridgHt*, *StoneBr*, dan *Crawfor* termasuk kawasan dengan harga rata-rata tertinggi.

Wawasan ini dapat dimanfaatkan oleh:

- Pengembang perumahan: untuk menentukan prioritas renovasi atau fitur yang meningkatkan nilai jual.
- Agen properti: untuk menetapkan harga jual realistis berdasarkan atribut rumah.
- Investor: untuk mengidentifikasi area investasi dengan nilai pertumbuhan tinggi.

7. Saran untuk Analisis Lanjutan

1. Menambah fitur geografis atau spasial, seperti jarak ke pusat kota atau fasilitas publik.
2. Menggunakan model interpretabilitas lanjutan seperti SHAP atau LIME untuk menjelaskan keputusan model ensemble.
3. Melakukan validasi silang (k-fold cross-validation) untuk memastikan performa stabil di berbagai subset data.
4. Mencoba model deep learning ringan (misal MLP Regressor) untuk melihat apakah pola non-linear lebih kompleks bisa ditangkap.
5. Menggabungkan data real estate terbaru untuk memperbarui model terhadap tren pasar modern.

8. Kesimpulan

Analisis ini menunjukkan bahwa:

- Model berbasis pohon keputusan (Random Forest & Gradient Boosting) memberikan hasil prediksi dan klasifikasi paling akurat.
- Faktor-faktor utama harga rumah adalah kualitas bangunan, ukuran, lokasi, dan umur rumah.
- Pendekatan kombinasi regresi dan klasifikasi memberikan pemahaman komprehensif: bukan hanya *berapa harga rumah*, tapi juga *mengapa harga tersebut terbentuk*.